





Clasificación de movimientos de rehabilitación

José Yael Varela García - A01645324
Miguel Ángel Rivas Torres - A01644628
Alejandra Gonzalez Burnes - A01286272

18 de Septiembre del 2026




Ejercicio de rehabilitacion que esta hacinedo el paciente



En China se hizo un programa de rehabilitación con 120 pacientes que se estaban recuperando de un derrame cerebral. Durante 2 semanas realizaron 16 ejercicios para recuperar el movimiento, mientras usaban sensores en el brazo o la pierna y un guante que mide el movimiento de los dedos.

¿Qué es el proyecto?

El reto consiste en predecir a qué ejercicio de rehabilitación (**movement_id**) corresponde una repetición registrada por los sensores, a partir de las features calculadas sobre esa señal.



Es decir, de una multitud de ejercicios (clases) nuestro modelo debe predecir basado en los datos de la muestra que ejercicio es

Conversión dataset

120

Pacientes con sensores

15

Clases usables (ejercicios)

4,257


muestras 212–385 por
clase


4257 filas

```
movement_id sample_id pitch1_min ... pitch3_std pitch3_mean pitch3_median
0 9 0 000_0 -51.937941 ... 77.233940 -3.100550e-15 -14.801629
1 8 0 000_1 -50.565684 ... 78.282052 1.033517e-15 -14.213077
2 7 0 000_2 -51.339183 ... 76.947035 1.033517e-15 -18.287711
3 6 0 000_3 -57.703826 ... 87.527223 1.033517e-15 -47.022745
4 5 0 000_4 -59.756789 ... 87.141703 -5.167584e-15 -34.596055
```

73 columnas



Cada repetición se resumió en 6 estadísticas por canal (min, max, range, std, mean, median), así una serie de 880 puntos se convierte en un vector fijo de 72 números es decir se tienen 72 filas de features (73 contando la etiqueta).






¿Se tuvo una limpieza de datos?

Durante la limpieza se excluyeron los datos del ejercicio 14 debido a un archivo faltante. Además, se trataron los valores anómalos mediante clipping con Z-score, es decir, estos valores anómalos fueron remplazados por su límite.





¿Qué se hizo para dividir los datos?

Separamos el 20% de test una sola vez, con semilla fija, antes de comparar modelos o afinar hiperparámetros

ENTRENAMIENTO


80%

3,405 muestras

TEST


20%

852 muestras



¿Cómo funciona el cross-validation?

Dentro del 80% de entrenamiento la validación rota 5 veces; el 20% de test nunca se toca






Comparación de 6 modelos (CV 5-fold, train)


Ranked by f1_macro:

model	f1	accuracy	precision	recall	fit_time
random_forest	0.953913	0.954772	0.955846	0.954373	1.682767
svm_rbf	0.864922	0.867254	0.867896	0.866578	0.136913
logistic_regression	0.827788	0.830543	0.831077	0.828870	1.357689
knn	0.800580	0.802643	0.807564	0.804818	0.002150
decision_tree	0.798065	0.799706	0.811188	0.796848	0.094498
naive_bayes	0.695106	0.706608	0.723691	0.706096	0.005863

Random Forest y SVM-RBF son los dos mejores



Random Forest



Mejor combinacion: (F1 = 0.949)

n_estimators= 200

max_depth=20


Resultados

Mejor combinacion: (F1 = 0.93)

C = 100

Gamma = auto

SVM (kernel RBF)



Modelo final:Random Forest

```
Ranked by f1_macro:
  model      f1  accuracy  precision  recall  fit_time
random_forest 0.957516 0.958297 0.959635 0.957837 1.632202
svm_rbf      0.925629 0.926579 0.927613 0.926613 0.136179
```

Random Forest obtuvo el mejor F1, aunque requiere más tiempo de entrenamiento. Como la diferencia de tiempo no es significativa, se selecciona como modelo final.

Resultados finales

ACCURACY

0.9624

PRECISION

0.9661

RECALL

0.9616

F1

0.9618

CORRECTAS



820 / 852


INCORRECTAS

32 / 852

Entrenamiento vs prueba

Diferencia de F1 entre entrenamiento y prueba: 0.0273. Sesgo bajo, varianza baja (good fit).





Resultados finales


Predicho																
Real	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0	46															
1		39	1									2				
2		1	51									1				
3				47				2		1						
4					52	1						4				
5						56						3				
6							49			1		2				
7								76				1				
8									58	2						
9										62						
10					1	1					60					
11												47				
12												4	54		1	
13					1					1		1		60		
15																63


Upper extremity combined training (Arm/Fingers/Wrist/Shoulder)	0	bobath handshake
	1	bobath flexion/extension
	2	bobath forward flexion/extension
	3	bobath anterior/posterior rotation
	4	elbow flexion and wrist compression
Hands training (Fingers/Wrist)	5	wrist flexion and extension
	6	finger-to-finger training
	7	ball gripping
Shoulder training (Shoulder)	8	shoulder joint internal and external
	9	breast expansion
Arm training (Arm)	10	flexion-pressure rotation forward and backward
	11	elbow joint flexion and touch
	12	shoulder touch training
Lower limbs training (Ankle/Knee/Hip)	13	Ankle extension & Knee internal and external rotation
	14	knee flexion and extension
	15	Hip flexion and extension

bias: bajo

varianza: baja


fit: good fit





Contribuciones personales

Integrante	Aportación a la solución
José Yael Varela García	Dataset, Entrenamiento Modelo Final, Comparación de Modelos
Miguel Ángel Rivas Torres	Tunning de Hiperparametros, Aporte entrenamiento de Modelo Final y Regularización
Alejandra Gonzalez Burnes	Página Web, detección de outliers, presentación.



Conclusiones

Logramos convertir las señales de los sensores en datos sencillos y, después de comparar seis modelos, elegimos Random Forest por ser el que mejor reconocía los ejercicios.

En la prueba final acertó 820 de 852 repeticiones (F1 de 0.9618), y como su desempeño en entrenamiento y en prueba fue muy parecido, sabemos que el modelo aprendió bien y no solo memorizó los datos. Esto muestra que sí es posible identificar qué ejercicio hace un paciente solo con sensores, lo que podría ayudar a darle seguimiento a su rehabilitación incluso desde casa.

